

调度系统架构理论与实践

大数据平台工作流调度系统

天火@蘑菇街 - colorant @ Wechat







Agenda

调度系统背景知识

工作流调度系统基础理论和流派

我司Jarvis调度系统开发实践

- 系统架构
- 设计目标
- 现状和未来







调度系统分类

资源调度系统

- Yarn
- Mesos
- Omega
- Borg
- Fuxi
- Gaia
- Normandy

作业调度系统

- Oozie
- Azkaban
- Chronos
- Zeus
- Lhotse
- SchedulerX
- Elastic-job
- Saturn





作业调度系统-定时分片类系统

场景定位

- 将一个作业拆分成多个小任务,分布式执行
- TBSchedule, SchedulerX, Elastic-job, Saturn

关注目标

- 不漏不重,负载均衡,弹性扩容,失效转移
- 精确定时触发,强实时性和高可靠性

业务影响

- 对所调度的任务往往有代码侵入性要求
- 有些系统还要求常驻Daemon进程,用于协调本地作业的管理和通讯



作业调度系统-DAG工作流类系统

场景定位

- 所服务的往往是流程依赖比较复杂的场景
- 可能涉及到成百上千个相互交叉依赖关联的作业
- Oozie, Azkaban, Chronos, Zeus, Lhotse, Jarvis

关注目标

- •丰富灵活的触发机制:时间,依赖,混合
- 灵活的作业变更管理,流程管控
- 优先级管理, 业务隔离, 错误跟踪, 异常报警
- 系统和业务健康度监控, 性能优化和问题诊断



THUS THINGS FLOW AWAY DAY AND NIGHT







工作流调度系统的两种心法流派

- 概念: 作业计划和任务实例
- 工作机制和代表系统

静态执行列表

根据作业计划 提前生成并持久化任务执行列表

遍历检查列表 满足条件触发执行

代表: Oozie, Azkaban 众多公有云上的workflow服务

动态执行列表

不提前固化任务执行列表 根据触发条件动态生成

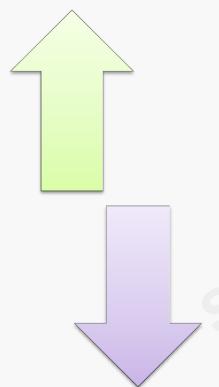
通过时间或上游任务触发 根据当前依赖关系生成任务实例

> 代表: Zeus, chronos 我司的Jarvis调度系统





两种流派的优缺点



静态执行列表方案

- 系统架构和运行逻辑相对简单
- 容易分析问题
- 能处理的场景也比较有限。

动态执行列表方案

- 能覆盖的场景范围更广
- 计划变更响应更及时
- 系统架构实现相对复杂

如果是在业务场景比较简单,任务依赖容易理清的场景下,静态执行 列表方案的系统维护代价会比较小。反之,则应该考虑构建动态执行 列表方案的系统



工作流的定义管理方式

静态显式定义和管理工作流

- oozie, azkaban以及各种公有云的workflow服务
- 用户需要显示定义一个工作流,包含哪些作业,依赖关系如何

动态隐式定义和管理工作流

- Chronos, Zeus和我司的Jarvis调度系统
- 管理维度是作业,用户定义的是作业之间的依赖关系
- 哪些作业构成一个工作流,系统实际上并不关心,用户也不需要申明

那两种处理方式各有什么优缺点呢?

- 前者,适合工作流规模较小,作业没有交叉依赖,依赖不会频繁变更的场景
- 后者,用户无需理会工作流这个概念,作业流程变更操作简单



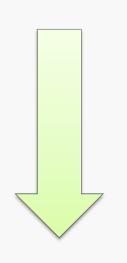


在广阔天地里茁壮成长





Why another Scheduler



业务环境需求

- 应用环境复杂,用户需求多变
- 周边组件众多,需要对接各种存储, 计算,查询和用户管理组件
- 血缘管理,权限隔离,负载流控,监 控报警,质量分析

现有系统问题

- 功能形态简单,需要大量二次开发
- 流程框架封闭, 很难对接外部系统
- 缺乏管理手段,使用和运维代价高

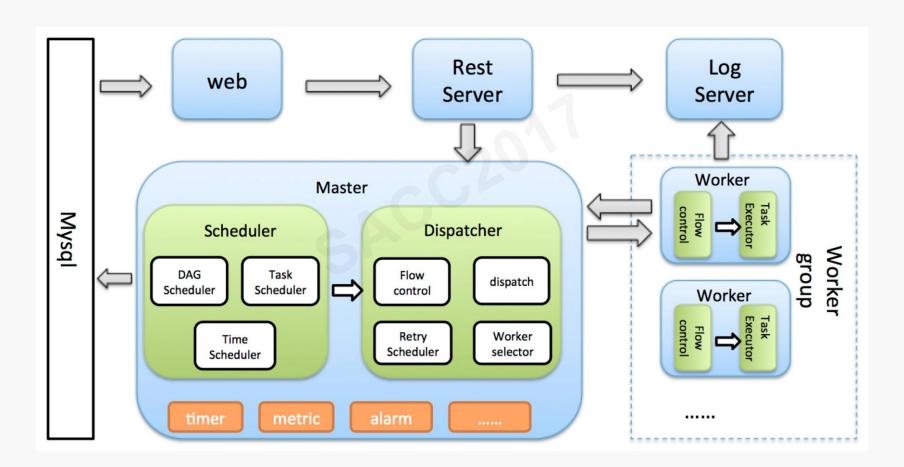






系统架构

• 目标: 高可用, 组件模块化, 无状态化





Jarvis 2 设计目标-系统

核心调度逻辑

- •准实时调度,计划的变更,即时生效,支持短周期任务
- •时间触发,依赖触发或者混合触发,支持多种范围依赖关系
- •根据血缘信息,自动建立作业依赖关系
- 调度时间和数据时间的分离

多租户环境

- 内建流控机制,Worker端负载均衡
- 支持作业优先级管理, 支持业务分组管理
- •和各种周边系统和底层存储计算框架即有的权限体系灵活对接

系统架构集成

- •组件模块化,核心组件无状态化
- •丰富的作业类型,能够灵活拓展
- ●开放系统接口,对外提供REST API,便于对接周边系统
- 支持灰度功能,允许按特定条件筛选作业按照特定的策略灰度执行





Jarvis 2 设计目标-产品交互

用户后台作业管理

- 用户可以自主通过交互界面的对作业进行添删改,对任务进行重跑等
- 支持对当日任务计划和历史运行流水,运行日志的检索
- 支持作业元数据信息检索,包括作业概况,变更记录,依赖关系树等。

作业执行逻辑管理

- 支持作业失败自动重试,可以设置自动重试次数,重试间隔等
- 支持历史任务独立重刷或按照依赖关系重刷后续整条作业链路
- 允许设置作业生命周期,可以临时禁止或启用一个周期作业
- 支持动态按应用 / 业务 / 优先级等维度调整作业执行的并发度

任务运行状态管理

- 支持任务失败报警,超时报警,等异常情况的报警监控
- 支持任务日志分析,自动识别错误原因和类型





服务好更多用户

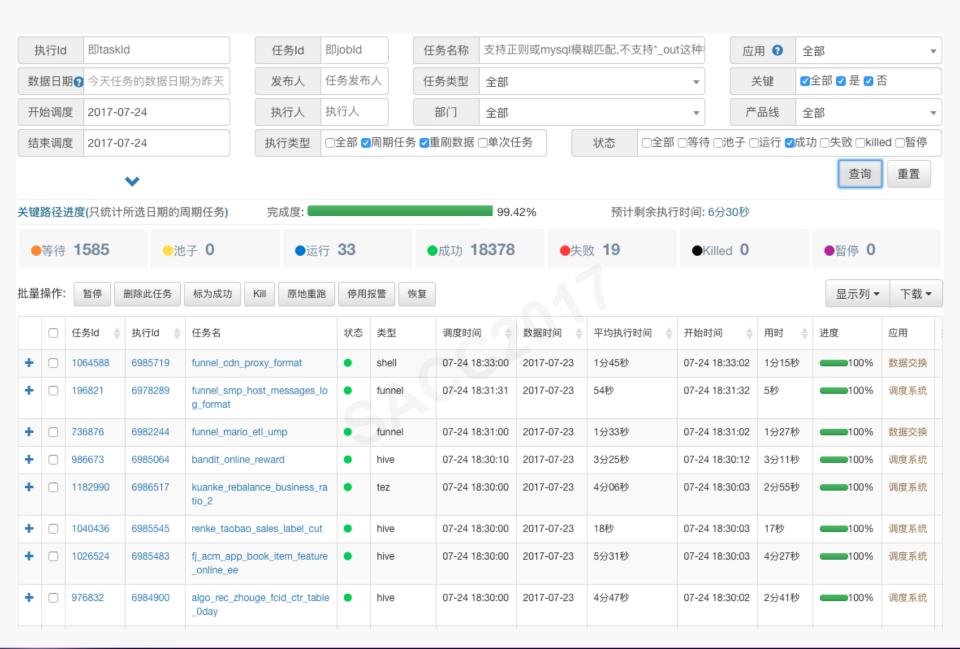
业务环境和问题

- 公有云工作流调度系统
 - 租户之间完全独立,租户之间的业务很难相互关联
 - 工作流之间几乎完全独立
- 我司业务环境
 - 业务相互依赖关系复杂,组织重构,业务变更也比较频繁
 - 在同一业务内部,也有不同的资源和流控管控需求。

Jarvis 2应对上述问题,主要实现并支持如下功能

- 作业优先级:核心业务,非核心业务,优先等级,失败重试任务等
- 多维度并发度控制: 作业类型,应用类型,调度类型和优先级类型
- 负载均衡: 工作节点的被动负载反馈和调度节点的主动负载均衡





















Jarvis的现状和问题

现状

- 经过快两年的开发和持续改进,前文所设定的产品功能目标,基本上都已经实现
- 日常稳定承载约2万个固定周期调度作业,以及同样数量级的一次性任务作业和重刷任务作业

问题

- 部分业务逻辑实现过于定制化,不利于系统功能的后续拓展和调整
- 在突发峰值或者极端高负载情况下的系统稳定性还需要经历 更多的复杂场景来加以磨练



未来的改进计划

系统整体业务健康度检测和评估手段改进

- 系统监控评估
- 业务专家系统

自动测试体系的完善

- 单元测试不足以发现大流量负载,复杂并发场景下隐蔽Bug
- 需要构建随机生成测试用例和模拟组件失效模式的测试体系

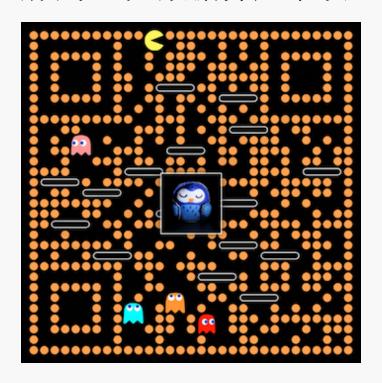
开源

- 开源不是一个目标, 而是用来提高产品质量的手段
- 重要的是开放思想,目的是让大家一起参与,共同努力,共同受益,而不是光晒代码



欢迎交流

- 以上内容,时间所限,大幅简化了,更多内容和细节
- 欢迎关注我的公众号"大数据务虚杂谈"



欢迎来人来函交流 天火@蘑菇街 - colorant @ Wechat



