

知乎大数据平台架构和实践优化

大数据平台负责人- 王雨舟









Outline

- 1. 关于知乎
- 2. 数据平台组
- 3. 数据平台架构









关于知乎











截止 2017 年 8 月

注册用户数



▲ 破亿

全站 DAU 达



△ 2600万











提问量达

▲ **1900**万

回答量达

▲ **7100**万

月浏览量

▲ 180亿







We are growing **FASTER**











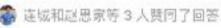


揭露dota2半开图外挂第一期



山水之间: (本文视频较多, 请流量党注意。) 转 载清注明作者知乎: 山水之间 大家好, 我是一名 dota玩家,最近我打入了一个dota外挂群内部并获...

522 想 - 127 评论 - 太往文章列表



为何现实中没有形成崇拜蒸汽之神,石油之神,电力之神,原子之神这样的宗教?



































寒唯

5天前

应邀之作《重返魔域》发布,欢迎朋友们试 听。

作曲/作词/演唱/制作人: 窦唯 录音/混音/制作执行: 陈林

t] 726



(7 10891



















...









●●●●○中国联通 令 互动分享会

Q搜索知平内容 互联网人的 阅读清单 6) 139 KG Live ■ 书店 😭 付费咨询

下午10:05

市场

每日新知

成长:如何跳出「换位思考」的陷阱 02:30

精品电子书

博圖:下雨天跟睡觉更配吗?

想法

心理: 爱「猜动机」小心走火入魔

▶免费播放全部

前页

査看更多う

02:08

02:29

线上语音解答

₩ 4 58% III







別章



页多

















书店







今天也要好好吃 饭 翠麗



大人如何读懂绘 本 (知产阶级...































旅途中你见过最美的日落是在哪里?



我本来以为在台北淡水渔人码头看的日落已经够美 了... [图片] 粉色的日落特别戳少女心... [图片]码头 那边一直有飞机飞过,飞的很慢~就觉得时间好...

10 赞同 · 3 评论 · 关注问题

● 美少女壮士

女生开豪/好车是一种怎样的体验?











电影话题

方禁闭甚至强制退伍的处罚,不过各... 展开全部

影人信息







余男 惟龙小石



使大红



信息证



忻 武吉







知息











新业务、新挑战

- +产品经理
- + 客户端开发
- + 后端开发
- + 数据分析师
- + 运营
- + 测试









数据平台如何在人员相对稳定的情况下

支撑公司业务快速扩张?







知乎数据平台的职责

- 1. 公司级数据平台
- 2. 维护基础流量数据和数据仓库
- 3. 维护算法、商业、搜索、后端服务需要的数据源
- 4. 为管理层、运营、产品、数据分析师等提供数据看板和分析系统
- 5. 维护数据地图、埋点管理系统、埋点配置和测试系统等产品
- 6. 维护 A/B 实验









快速满足新业务需求的过程

- 1. 流量数据埋点
- 2. 创建数据仓库
- 3. 创建数据源、指标、维度、报表
- 4. 创建业务看板







特点

- 1.用户能自定义创建报表
- 2. 秒级查询能力,解决指标开发人力投入与数据 T+1 的痛点
- 3. 自定义创建仪表盘数据







数据源导入













/user/hive/warehouse/ods_growth.db/user_visit_index/pdate=5{} 分区键与格式 选择 partition key 与格式,日期分票键的格式通常为 yyyyMMdd pdate 0 歷型加和数 浮点型加和数 时间列 整型最小值 选择表中时间列与格式化过 浮点型最小值 选择列... 🗘 整型最大值 浮点型最小值 指标 近似直方图指标(缺失值为0) 在 ZA 中出现的指标。设置 近似直方图指标(缺失值忽略) hash_id (string) 0 漳川 去重数 维度 在 ZA 中出现的维度、设置项分别为列名、类型与名称。不添加则自动以时间列、指标列以外的列为维度。 platform (string) 0 默认 0 添加 每日同步时导入的时间段 每次自动同步时同步的时间段,可以用于增量同步 昨天 🗅 同步频率 定时任务执行时间 208***

/user/hive/warehouse/ods_growth.db/user_visit_index/pdate=\${} 分区键与格式 选择 partition key 与格式,目期分期键的格式通常为 yyyyMMdd pdate 🤤 iso millis 时间列 posix 选择表中时间列与格 auto 选择列... 〇 比如 yyyy-MM-dd HH:m joda. 指标 在 ZA 中出现的指标,设置项分别为列名、类型与名称 hash_id (string) 0 去重数 🔾 hash_id 添加 维度 设置项分别为列名、类型与名称。不添加则自动以时间列、指标列以外的列为维度。 在 ZA 中出现的维度。 默はつ platform (string) 0 每日同步时导入的时间段 每次自动同步时同步的时间段,可以用于增量同步 昨天 🗘 同步频率 定时任务执行时间 20.8 * * * 東京が進行し みるし ((生まれ)

创建指标









创建指标

指标是数据的度量方式

名称与说明

指标的基本信息, 便于归类、查找

自定义指标

指标的介绍...

指标使用的聚合参数

指标是如何被定义的





加... | 減... | 乘... | 除...

访问权限

只有指定权限以上的人才可以选择该指标

分析师 ◊

单位与显示格式

美化指标的显示格式

数据单位

数字 🗘

显示格式

整数(四舍五入) 🗘

保存指标

创建多维分析报表









创建报表

通过指定的维度与指标创建报表,稍后在报表展示页面可以调整报表的时间范围、粒度

数据源

不同数据源有不同的指标与维度,在产品管理页面切换产品

知乎日报 〇

名称与说明

报表的基本信息, 便于归类、查找

Demo

报表说明

指标

通常以数字形式呈现,在图表上处于纵轴的位置。默认会以时间维度来切分数据

页面展示数 × 日志条数 × 选择指标

维度

可以以不同维度的值来切分数据

平台 × 选择维度

过滤器

对以上条件筛选出的日志进行进一步筛选

包含 🗘

平台

等于 🗘

AndroidPhone

默认查询粒度

可以为时间列查询设置默认查询粒度

天章

报表报警项

维度取值	指标	报警配置函数	粒度	操作
	京巫原士粉 A	fate attition in the	= ^	Œ la
平台	页面展示数 💠	(d1-d2)/d2 > 0.1	天≎	添加

把报表分享给...

将显示在他们的「向我分享的报表」下

搜索用户...

动态添加虚拟指标









自定义报表 添加虚拟指标 通过其他指标经过计算而定义的虚拟指标。 表达式 指标 以已有指标进行计算 点击设备数 + 推送成功设备数 指标、运算符或者数字组成的多项定 名称与备注 维度 将会显示在指标的介绍当中 名称 备注 过滤器 单位与显示格式 美化指标的显示格式。 数据单位 数字 〇 默认查询粒度 显示格式 百分比(保留三位有效数字) ◇ 天〇 把报表分享给.



ikback 频道提意见 上的 ZA 使用指南

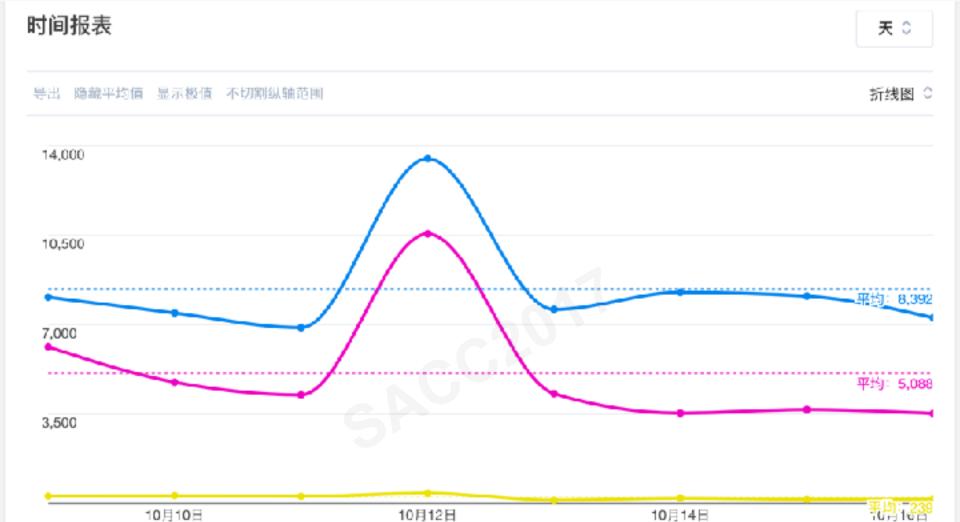




Х







AndroidPhone iPhone iPad

数据请求时间: 2017年10月17日 14时29分05秒 关闭报表查询通知 刷新报告数据 编辑报表 复制报表









创建留存报表









创建留存报表

通过规定指标、留存源过滤条件与留存目标过滤条件来创建留存报表

数据源

不同的产品(数据源)有不同的指标与维度、在产品管理页面切换产品

知乎日报 ≎

名称与说明

报表的基本信息,便于归类、查找

白定义留存报表

报表说明

指标

以指定指标作为留存查询的依据

终端数 ×

默认查询粒度

为留存报表设置默认的查询粒度与长度

天〇

7天留存 0

默认查询粒度 为留存报表设置默认的查询粒度与长度 天 ○ 7天留存 ○

维度

可以以不同维度的值来切分数据

选择维度

留存源过滤

对指定的留存指标进行过滤,进入留存查询范围

包含 🗘

是否为每日新终端

等于 🗅

true

留存目标过滤

对留存查询结果进行进一步过滤

十 添加过滤条件

整体过滤

同时对留存源与目标进行过滤

留存目标过滤

对留存查询结果进行进一步过滤

十 添加过滤条件

整体过滤

同时对留存源与目标进行过滤



等于 🗘

iPhone

把报表分享给...

将显示在他们的「向我分享的报表」下

搜索用户...

保存报表









周≎

7周留存 🗘

SACC App 留存 Demo

070

yuzhou 的报表,以 知乎用户会话 为数据源

显示指标维度 显示报表过滤条件

留存报表

以指定粒度来查看不同时长和粒度的留存

导出 隐藏总计百分比 表格 ○										
时间个	终端数	第1周	第2周	第 3 周	第4周	第5周	第6周	第7周		
28周	1,436	47 1	412	395	383	376	328	307		
	100%	32.799%	28.691%	27.507%	26.671%	26.184%	22.841%	21.379%		
29周	1,374	47 8	408	417	380	341	325	329		
	100%	34.789%	29.694%	30.349%	27.656%	24.818%	23.654%	23.945%		
30周	1,315	423	413	38 5	337	321	342	30 5		
	100%	32.167%	31.407%	29.278%	25.627%	24.411%	26.008%	23.194%		
31周	1,204	430	378	351	304	321	278	281		
	100%	35.714%	31.395%	29.153%	25.249%	26.661 %	23.09%	23.339%		
32周	1,224	414	3 82	336	348	306	331	289		
	100%	33. 82 4%	31.209%	27.451%	28.431%	25%	27.042%	23.611%		
33周	1,141 100%	384 33.655%	361 31.639%	331 29.01%	324 28.396%	317 27.783%	299 26.205%	-		
34周	1,070 100%	363 33.925%	337 31.495%	317 29.628%	308 28.785%	291 27.196%		-		
35周	950 100%	369 38.842%	321 33.789%	293 30.842%	290 30.526%	-	-	-		

搭建可视化看板









添加报表卡片

仪表板中的报表卡片

名称

留空时默认使用报表名称。可以替换

名称

报表

卡片对应的报表

SACC App 留存 Demo × 摄索报表...

展示方式

报表在仪表板中的请求类型与展示样式

时间报表 🗘

表格 〇

添加报表卡片











2017年10月07日 - 2017年10月14日

编辑卡片

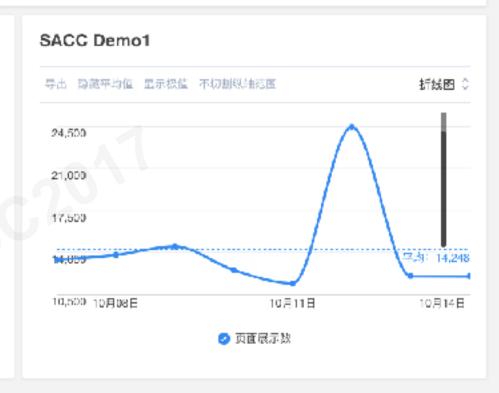
编辑基本信息

添加报表

SACC App 留存 Demo

导出 隐藏总计百分比 表格 🗘

时间 ↑	終編 數	第 1 天	第 2 天	第 3 天	篇 4 天	第 5 天	第 6 天	第 7 天
10月 07日	225 100%	91 40,44 454	83 38.88 9%	85 37.77 8%	79 35.11 196	76 33.77 8%	62 27.55 6%	64 28.44 4%
10月 08日	222 100%	93 41.89 294	83 37.38 796	85 38.28 8%	84 37.83 896	73 32.88 394	71 31.98 296	0 0%
10月 09日	219 100%	94 42.82 294	94 42.82 296	85 38.81 3%	71 32.42%	70 31.86 394	0 034	0%
10月 10日	2012 100%	93 40.08 6%	81 34.91 466	76 32.75 3%	74 31.89 7%	0 0%	0 0%	0 0%
10月 11日	212 100%	94 44.84%	77 36.32 196	77 96.32 1%	0 0%	0 0%	0 0%	0 0%



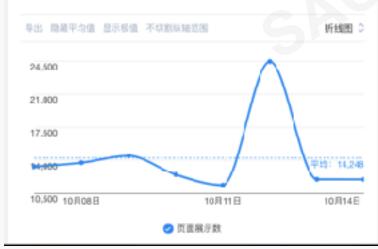






SACC App 留存 Demo 2012 2012 早出 隐能总计百分比 表格 🗘 终键数 时间↑ 第1天 第2天 第3天 第4天 第5天 第6天 第7天 91 83 85 79 76 62 64 10月07日 40.444% 3688916 37.178% 35.111% 33.778% 27.556% 23.444% 93 71 0 83 85 73 10月08日 41,892% 3738716 38.288% 37.838% 32.843% 31.982% 0% 94 0 71 70 0 10月09日 40,000% 4202216 38.813% 32.42% 31.04396 096 996 73 0 0 10月10日 40.086% 3491416 32,759% 31.897% 0% D96 096 94 0 0 0 77 77 0 10月11日 44.34% 3632116 36.321% 0% 0% 0% 096 0 0 0 0 77 78 0 10月12日 00.92156 3430116 0% 034 0% D96 036 75 0 0 0 0 0 0 10月13日 016 0% 0% 0% 0% 0% 37,129%

SACC Demo1







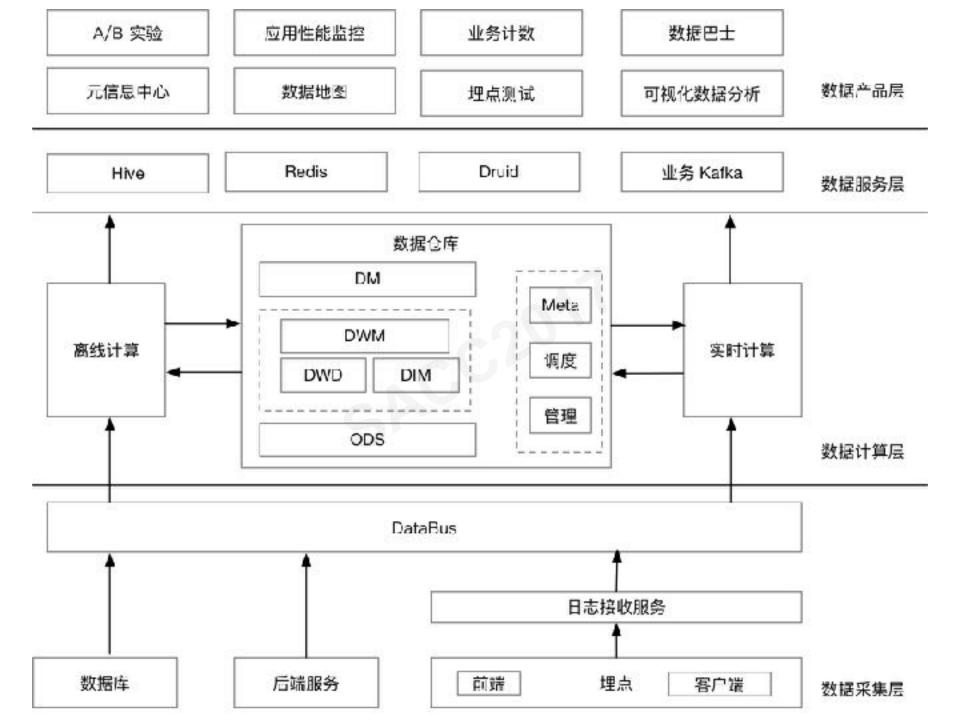
数据平台架构











数据采集

- 客户端和前端采用 Protobuf 格式打点
- Hybrid 框架,保证 JS 和 Native 打通
- 客户端更关注埋点定位,内容数据由后端序列化生成下发









日志接收

- 自研日志接收服务,发送到 Kafka
- 能自适应 Kafka 健康状态,保证数据不丢









数据传输

- Kafka -> HDFS,支持 Protobuf 格式
- Mysql -> Kudu, Mysql -> Hive
- Hive -> Druid, HBase -> Druid







计算

- Spark Streaming
- MapReduce
- Druid
- Hive, Impala









数据仓库

- 数据分层
 - ODS
 - DMW、DIM、DWD
- 星形模型
 - 事实表和维度表
 - 事实表采用退化维度,减少关联多表操作







