# 大容量redis存储方案--Pika



陈宗志
360基础架构组技术经理

# 简介

- 13年入职360 基础架构组
  - Bada
  - Pika
  - Zeppelin
  - Mario, Pink, slash, floyd
- https://github.com/Qihoo360

# 概要

- 存在问题
- 分析问题
- 解决问题
- Pika vs redis

# Introduction

- Pika 是DBA 和 基础架构团队一起设计开发的大容量redis的解决方案
- 完全兼容redis 协议, 用户不需要修改任何代码进行迁移

# Pika User

- Redis实例数量：6000+个
- 日访问量：5000+亿

- Pika数据数量：1000+个
- 日访问量：1000+亿
- 覆盖率：80%以上业务线
- 单份数据体积：6.8T

## UserList


More

# Pika 定位

Pika 的出现并不是为了替代 Redis，而是 Redis 的场景补充。

Pika 力求在完全兼容 Redis 协议、继承 Redis 便捷运维设计的前提下通过持久化存储的方式解决 Redis 在大容量场景下的问题

# Redis 问题

- 恢复时间长
- 一主多从, 主从切换代价大
- 缓冲区写满问题
- 成本问题

# Redis 问题

- 恢复时间长
  - 50G redis 回复时间70分钟
  - 同时开启aof 和 rdb

# Redis 问题

- 一主多从, 主从切换代价大
  - 主库挂掉后升级从库, 所有的从库全部重传数据

# Redis 问题

- 缓冲区写满问题
  - 内存是昂贵资源, 缓冲区一般设置2G
  - 网络原因很容易将数据堵死, 那么就会发生大量数据重传

# Redis 问题

- 内存太贵
  - 线上使用的redis 机器是 64G, 96G. 只使用 80% 的空间.
  - 如果一个redis 的实例是50G, 那么基本一台机器只能运行一个redis 实例. 特别的浪费资源

# Redis 问题


**90/GB VS 2.6/GB**

**30倍的差距**

# 问题分析

- 成本问题
- 可用性问题
- 同步问题
- 易用性问题

# 问题分析

- 尽可能兼容redis 协议
- 使用基于磁盘的存储引擎rocksdb 实现多数据接口接口
- 网络库
- 添加binlog 模块

# Pika 整体结构

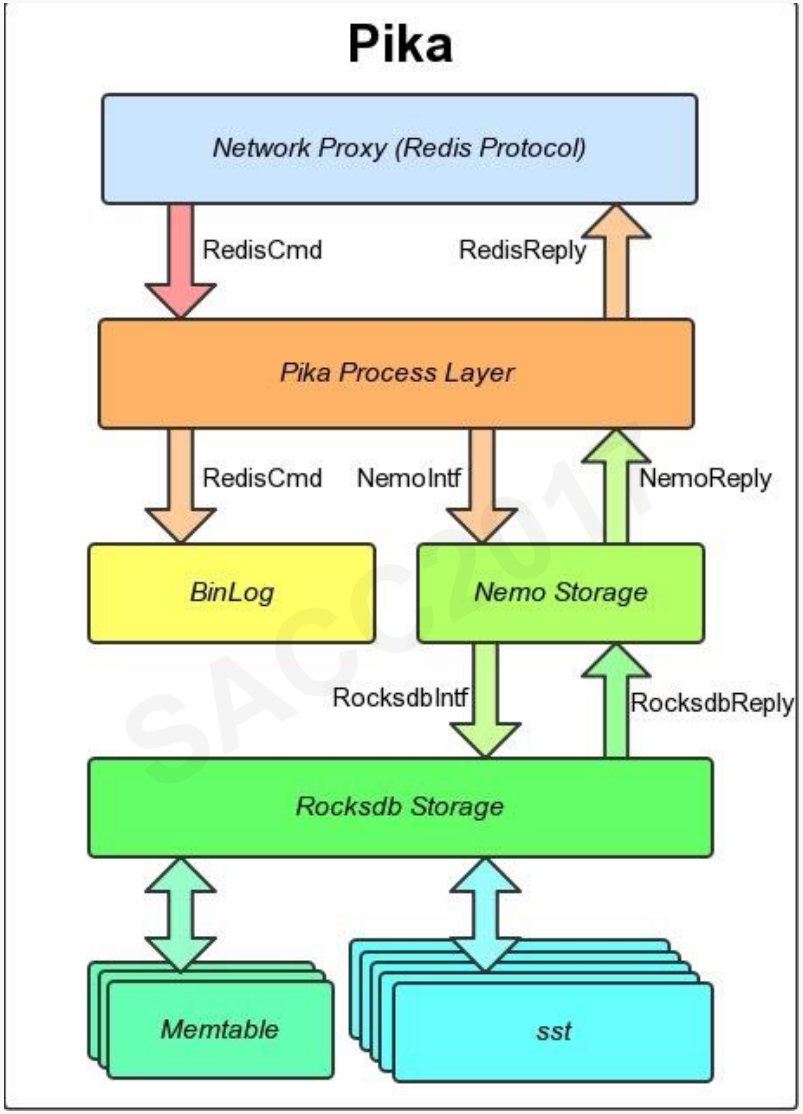

# 网络模块--Pink

- 基础架构团队开发网络编程库, 支持pb, redis, pg, http等协议.
- 抽象各种不同类型线程
  - DispatchThread
  - WorkThread
  - BGThread
- https://github.com/Qihoo360/pink

# 网络模块--Pink

- 稳定行, 在各个项目中使用4年多
- 易用性
- 高性能

# 网络模块--Pink

```
class MyPbConn : public pink::PbConn {
Public:
 MyPbConn(int fd, std::string ip_port, pink::Thread* self_thread_ptr = NULL) : pink::PbConn(fd, ip_port) {
  res_ = dynamic_cast<google::protobuf::Message*>(&message_);
 }
 ~MyPbConn() {}
 int DealMessage() {
  message_.ParseFromArray(rbuf_ + cur_pos_ - header_len_, header_len_);
  message_.set_name("hello " + message_.name());
  uint32_t u =htonl( message_.ByteSize());
  memcpy(static_cast<void*>(wbuf_), static_cast<void*>(&u), COMMAND_HEADER_LENGTH);
  message_.SerializeToArray(wbuf_ + COMMAND_HEADER_LENGTH, PB_MAX_MESSAGE);
  set_is_reply(true);
 }
```

# 网络模块--Pink

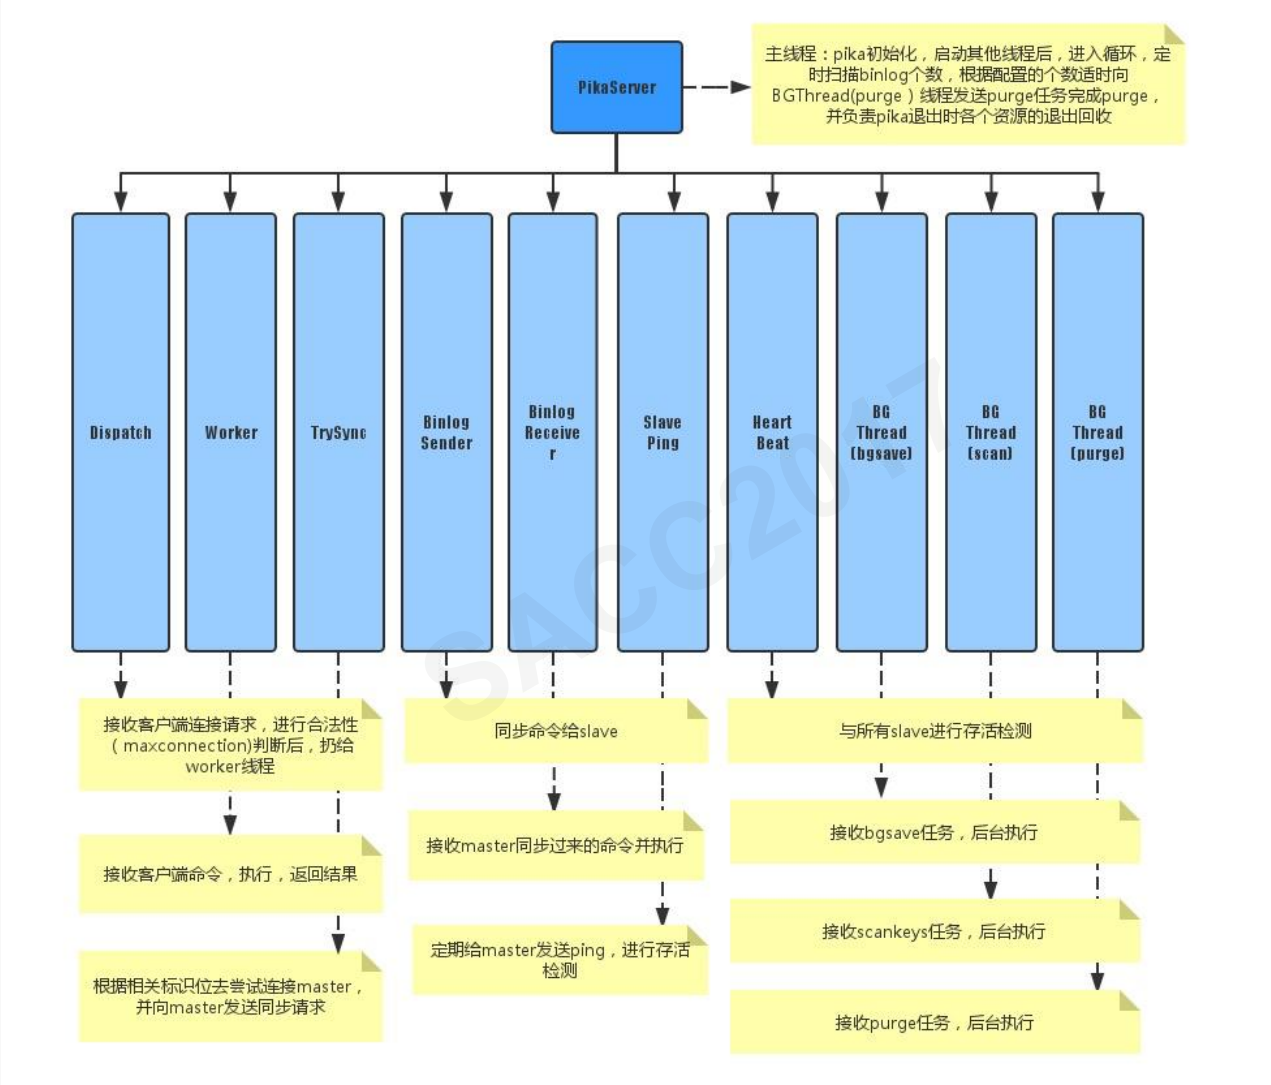
PikaServer
主线程：pika初始化，启动其他线程后，进入循环，定时扫描binlog个数，根据配置的个数适时向BGThread(purge）线程发送purge任务完成purge，并负责pika退出时各个资源的退出回收
Dispatch
Worker
TrySync
Binlog Sender
Binlog Receiver
Slave Ping
Heart Beat
BG Thread (bgsave)
BG Thread (scan)
BG Thread (purge)
接收客户端连接请求，进行合法性（maxconnection)判断后，扔给worker线程
接收客户端命令，执行，返回结果
根据相关标识位去尝试连接master，并向master发送同步请求
同步命令给slave
接收master同步过来的命令并执行
定期给master发送ping，进行存活检测
与所有slave进行存活检测
接收bgsave任务，后台执行
接收scankeys任务，后台执行
接收purge任务，后台执行

# 存储引擎--Nemo

- Nemo
  - Pika 的存储引擎, 基于Rocksdb 实现. 实现了Hash, List, Set, Zset 等数据结构
  - Rocksdb 启动只需要加载log 文件
  - Rocksdb 使用的本地硬盘, 对SSD 盘友好
  - https://github.com/Qihoo360/nemo

# 存储引擎--Nemo

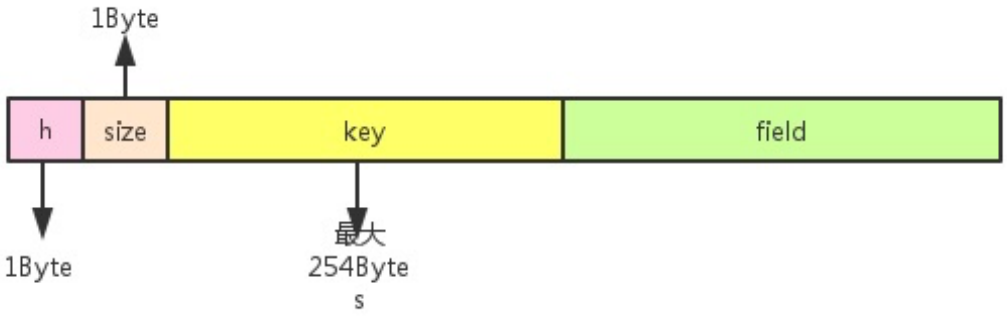


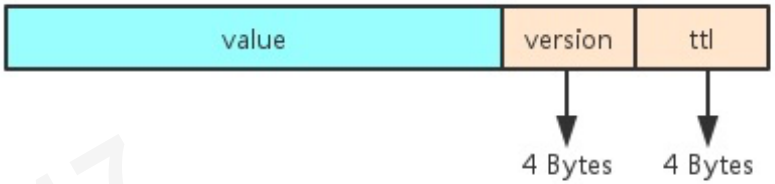



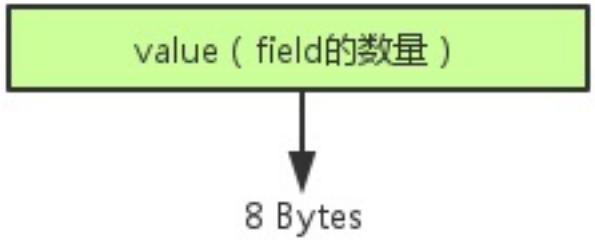

# 存储引擎--Nemo

- HSET myhash field1 "Hello"
  - DB->Put(wop, h6myhashfield1,Hello01477671118)
  - DB->Put(wop, Hmyhash11477671118, 6)

# 存储引擎--Nemo

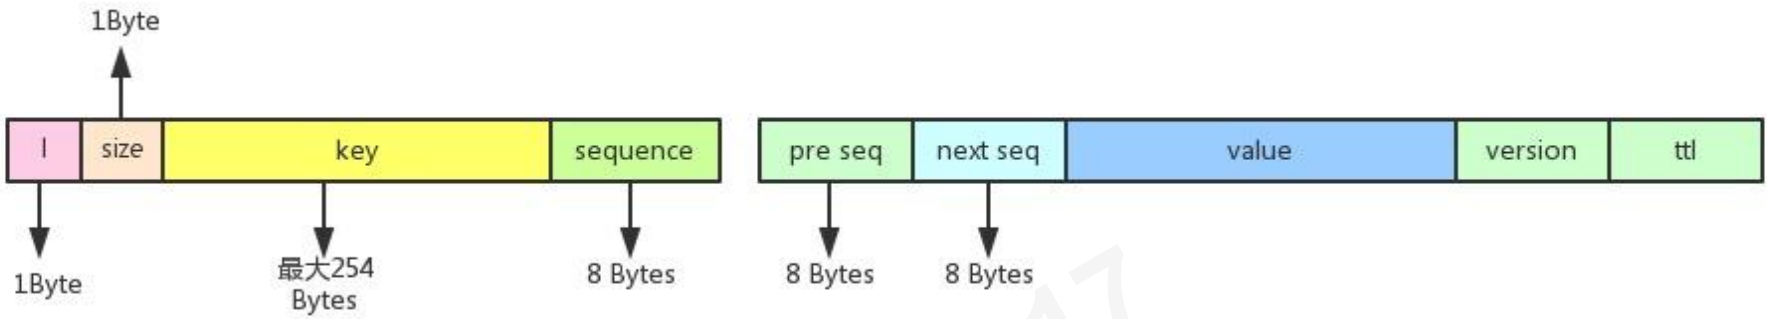


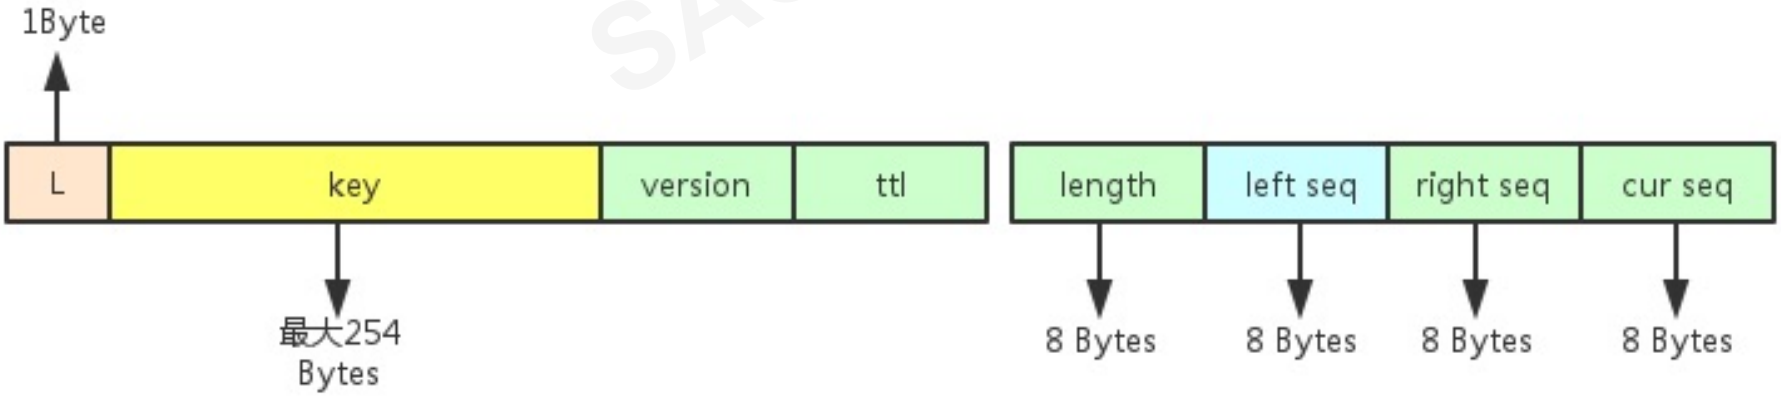

# 存储引擎--Nemo

- LPUSH mylist "world"
  - DB->Put(wop, l6mylist6, 57world01477671118)
  - DB->Put(wop, Lmyhash11477671118, 6071)

# 日志模块--Binlog

- Binlog
  - 顺序写文件, 通过Index + offset 进行同步点检查
  - 解决了缓冲区小的问题
  - 支持全同步 + 增量同步

# 日志模块--Binlog

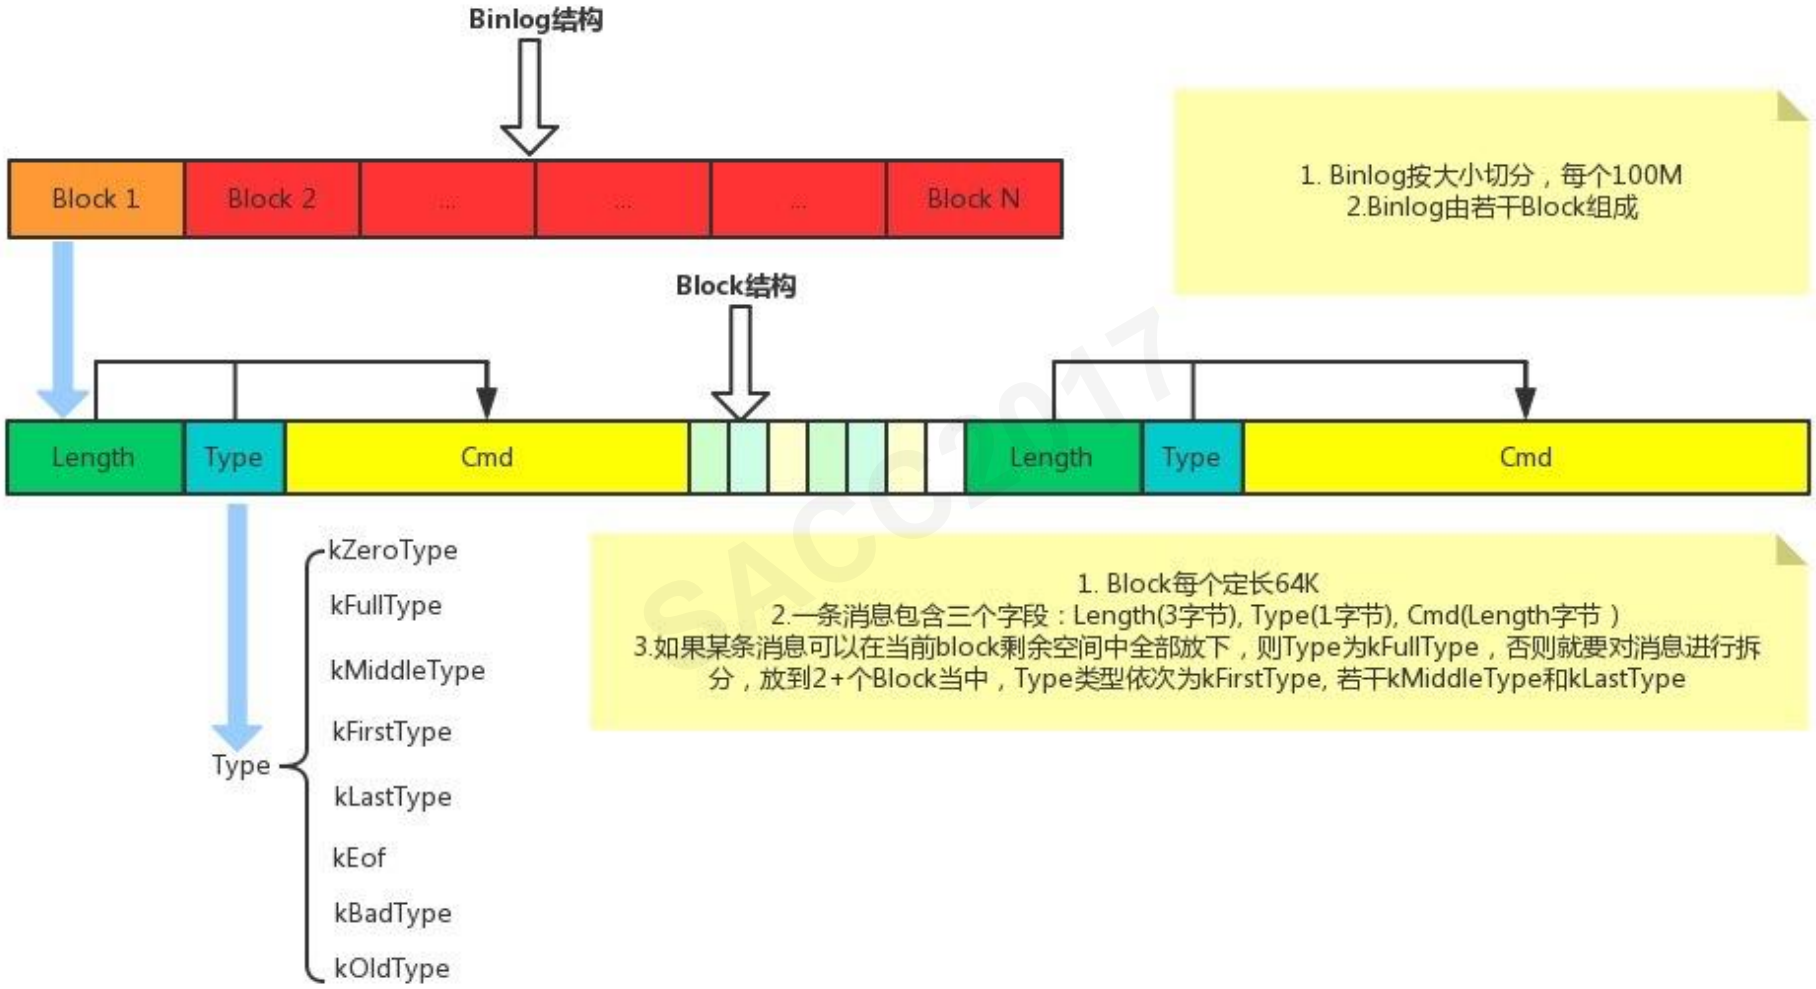

# 主从同步-- slaveof

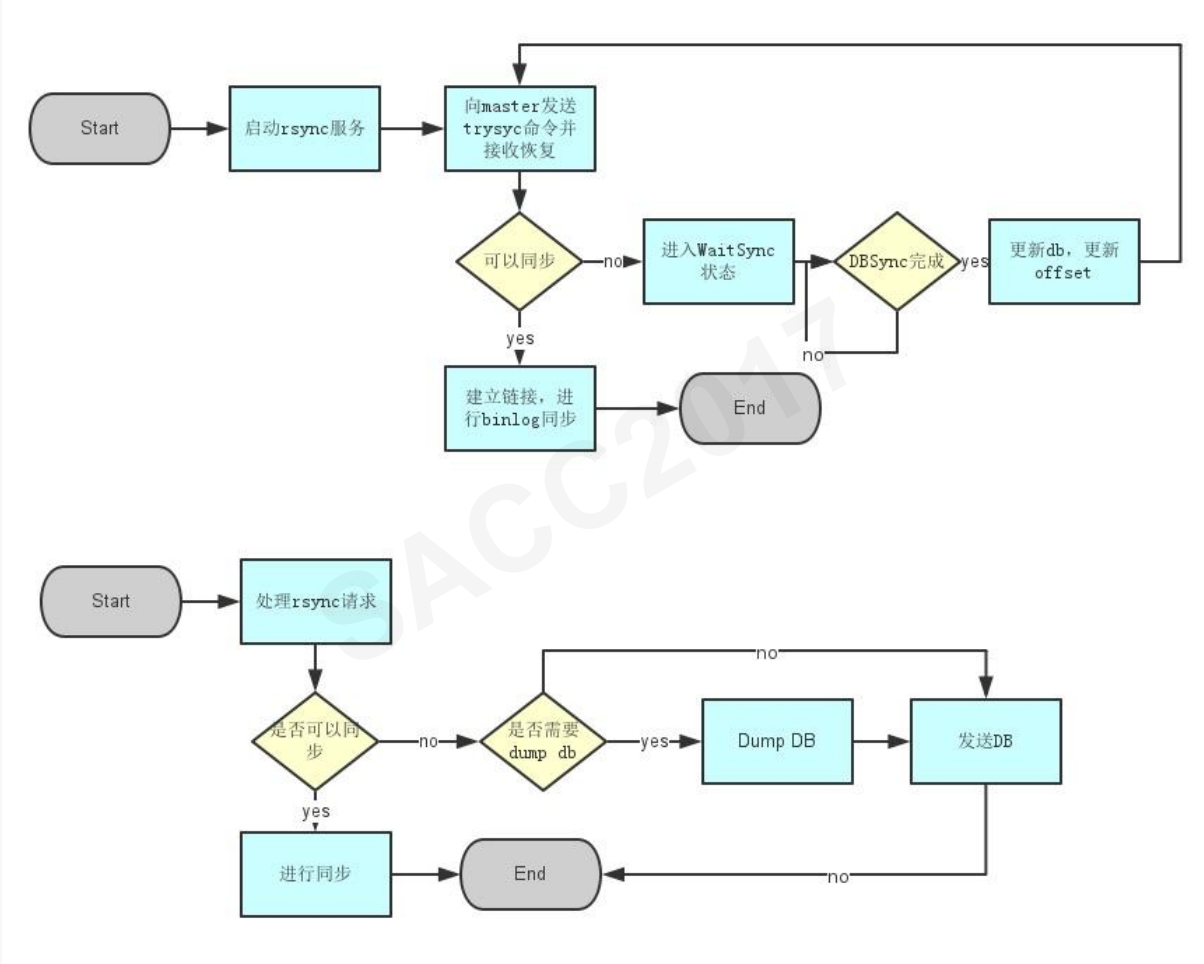

# 主从同步-- slaveof

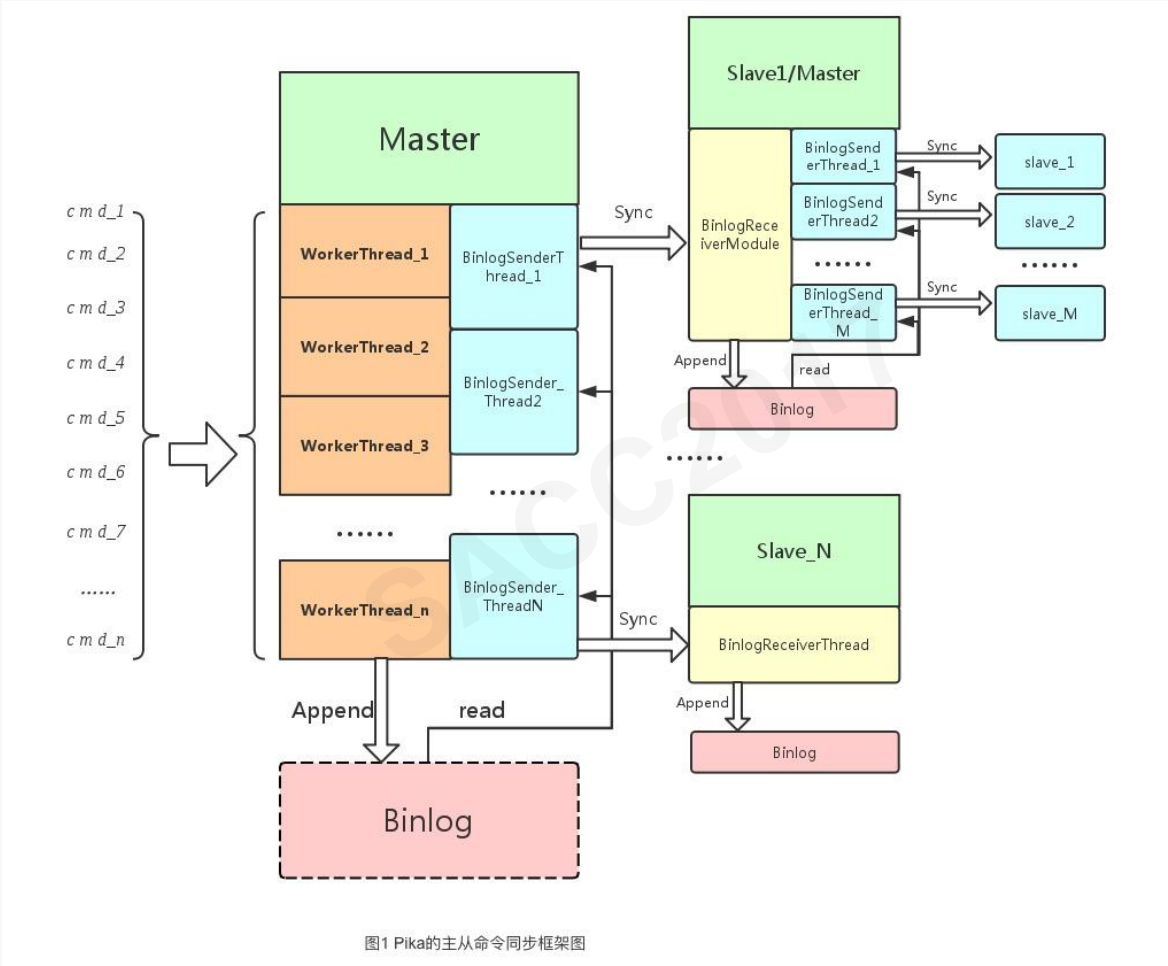


图1 Pika的主从命令同步框架图

# Pika 遇到问题

- 秒删
  - 通过修改Rocksdb, 增加 version, timestamp 字段.删除只需要修改metadata
  - 支持亿级别数据秒删

# Pika 遇到问题

- 数据compact
  - 修改Rocksdb manual compact 策略, 支持低优先级的 manual compact
  - 根据机型调整rocksdb 配置, compac线程, memtable 个数
  - 晚上定期执行

# Pika 遇到问题

- 数据备份
  - 需要rocksdb 和 Binlog 配合

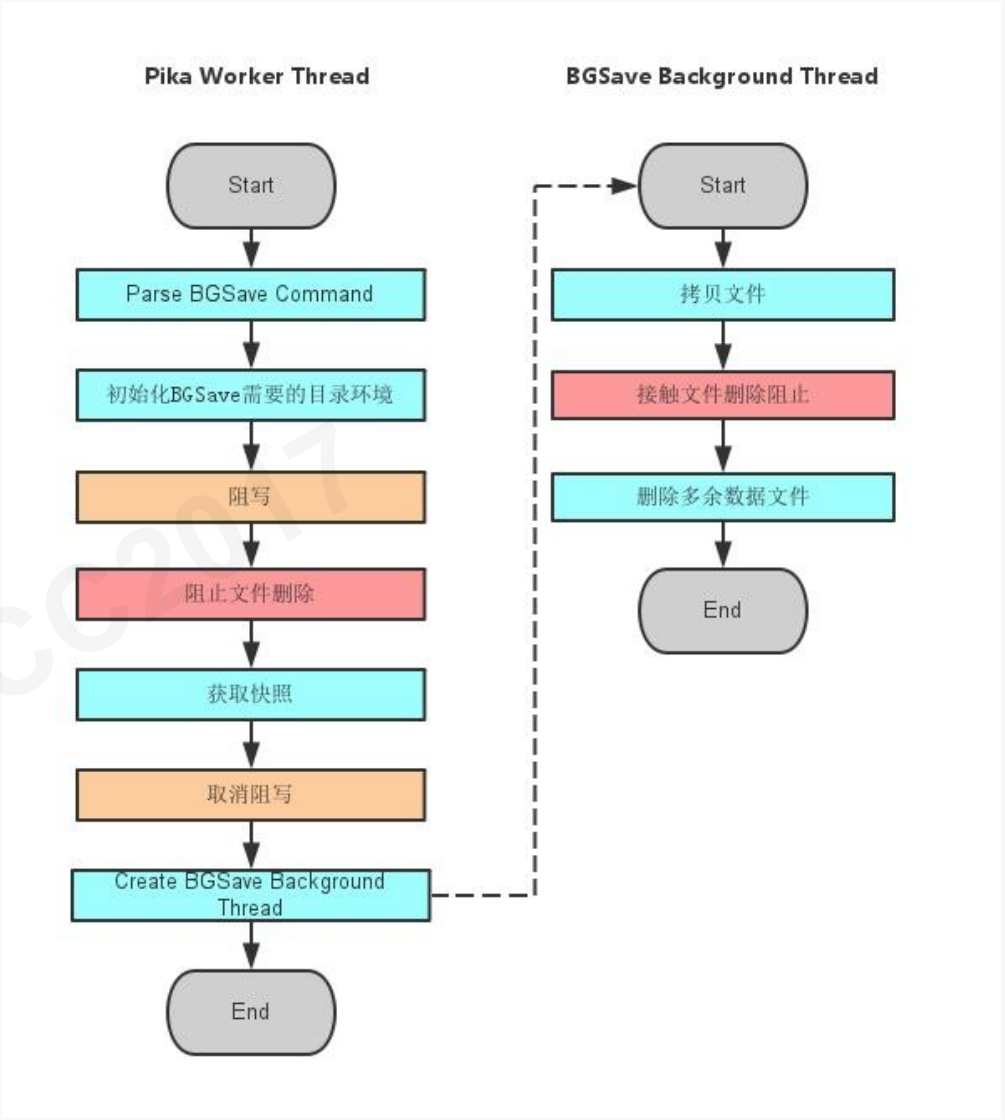

# Pika 运维 – 线上架构

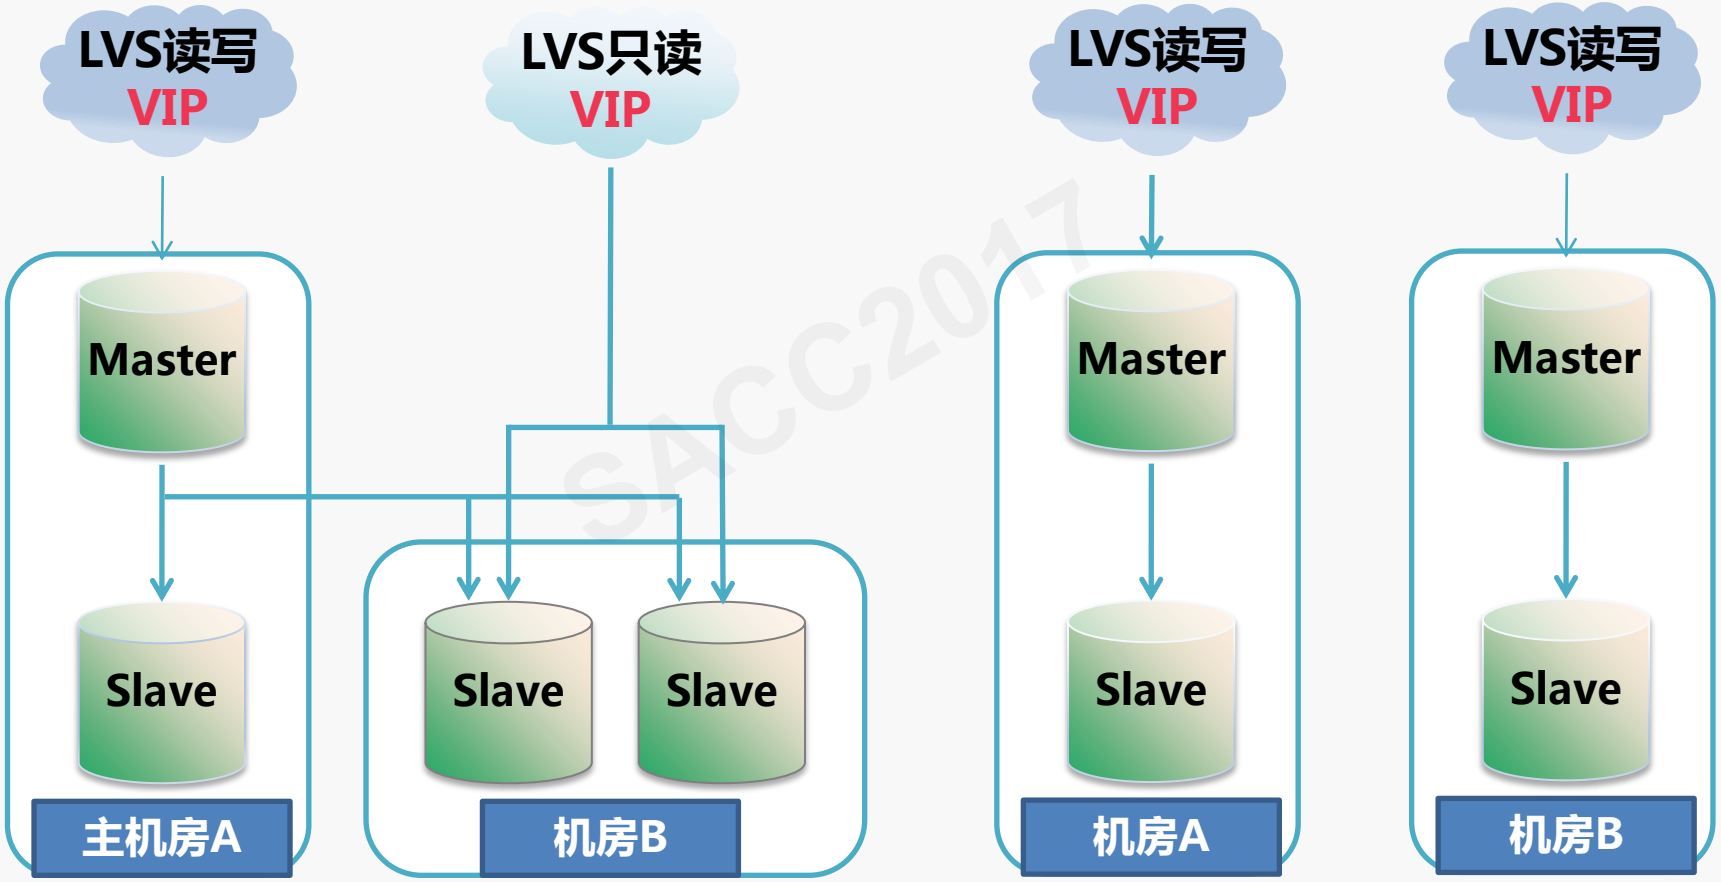

# Pika 运维 – 线上架构

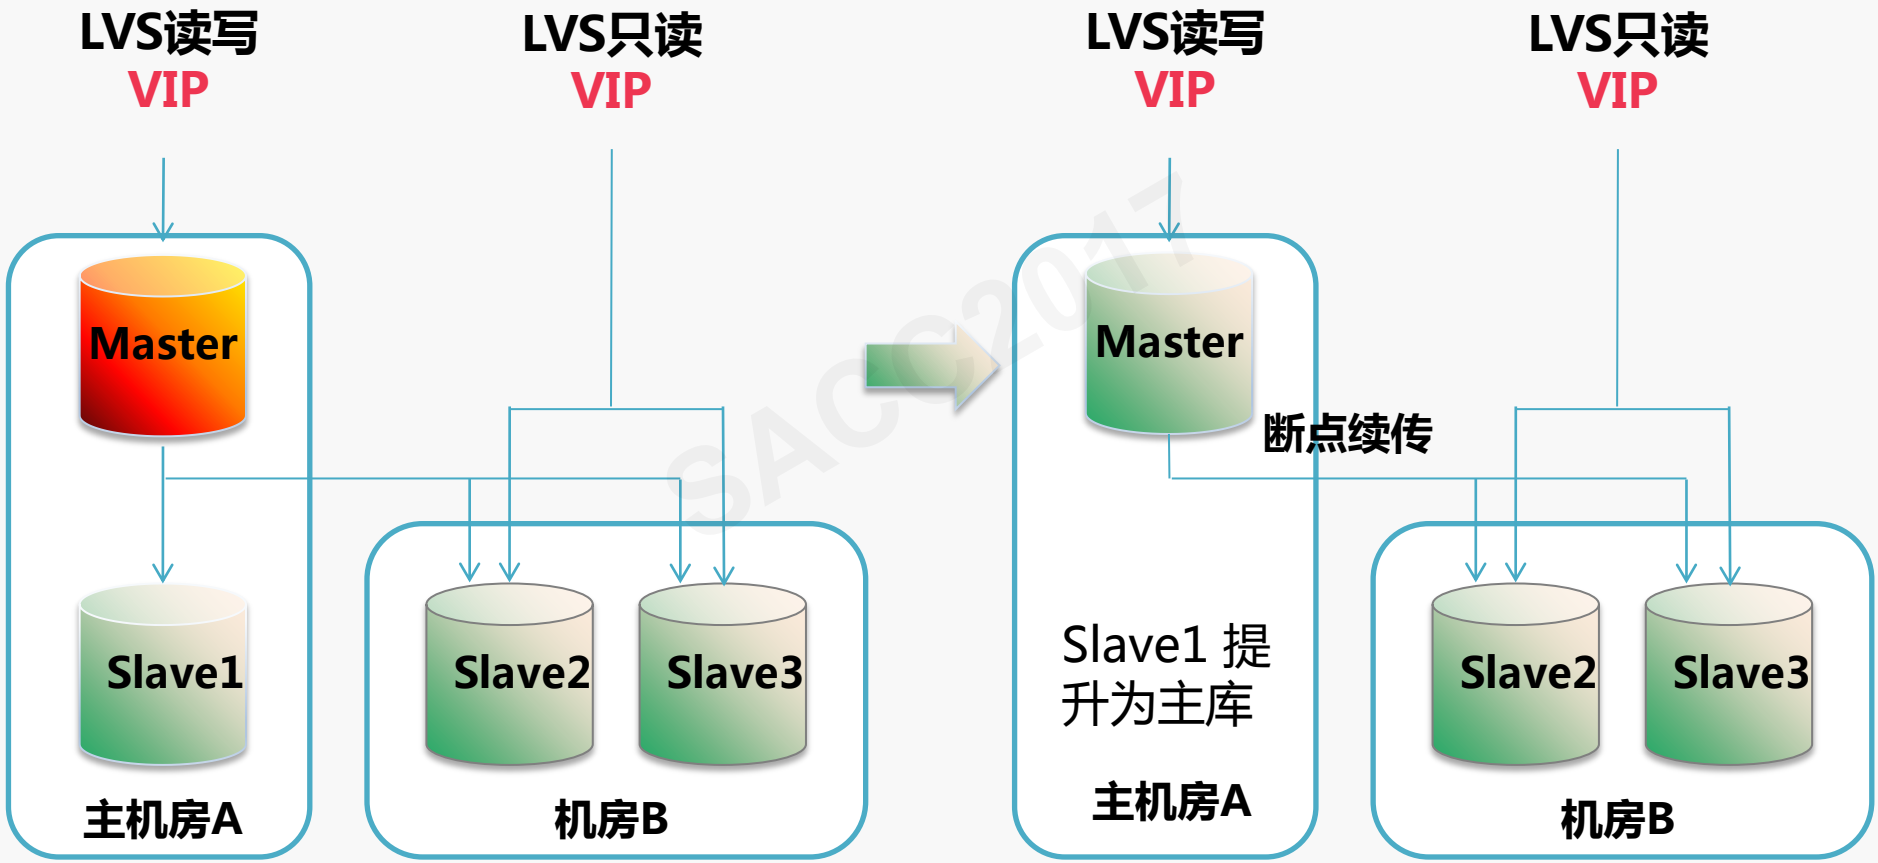

# Pika 运维 – 迁移工具

- Redis_to_pika
  - 将redis数据迁移到pika，基于aof，能全量+增量方式同步数据（Note关闭aof重写）
- Pika_to_redis
  - 业务增长过快，pika逐渐难以支持性能，将pika迁回redis，支持增量数据同步
- Ssdb_to_pika
  - 将ssdb数据迁移到pika，目前不支持增量同步

# Pika 运维 – 案例一

## 消息推送服务部分redis迁移到pika

- 迁移前：
  - SET数据结构为主
  - 5套30G左右的redis主从，占用300G内存
- 迁移后：
  - 1套50G左右的pika主从，占用100多G磁盘

# Pika 运维 – 案例二

数据分析业务redis迁移到pika

迁移前：

业务数据量增长迅速，上线不到1周数据量增长到40G

迁移后：

1套100G+ Pika主从

# Pika 开发现状

- Pika团队目前有2个主力开发维护，2个DBA做需求分析讨论、性能测试、bug跟踪、回归测试。积累1700+个测试用例
- 产品经理汇总github问题和交流群用户反馈,帮用户问题解决和需求排期开发
- 一月一个小版本, 二月一个大版本

# Pika 开发现状

- 双主支持
- Pika_hub 提供多机房写入支持
- 支持sentinel
- 支持codis

# Pika 总结

- 恢复时间长
- 一主多从, 主从切换代价大
- 缓冲区写满问题
- 内存昂贵问题

# Pika vs redis

- 劣势
  - 由于Pika是基于内存和文件来存放数据, 所以性能肯定比Redis低一些
- 优势
  - 容量大
  - 加载db速度快
  - 备份速度快
  - 对网络容忍度高
  - 性价比高

# Pika vs redis

- CPU: 24 Cores, Intel(R) Xeon(R) CPU E5-2630 v2 @ 2.60GHz
- MEM: 165157944 kB
- OS: CentOS release 6.2 (Final)
- NETWORK CARD: Intel Corporation I350 Gigabit Network Connection

# Pika vs redis

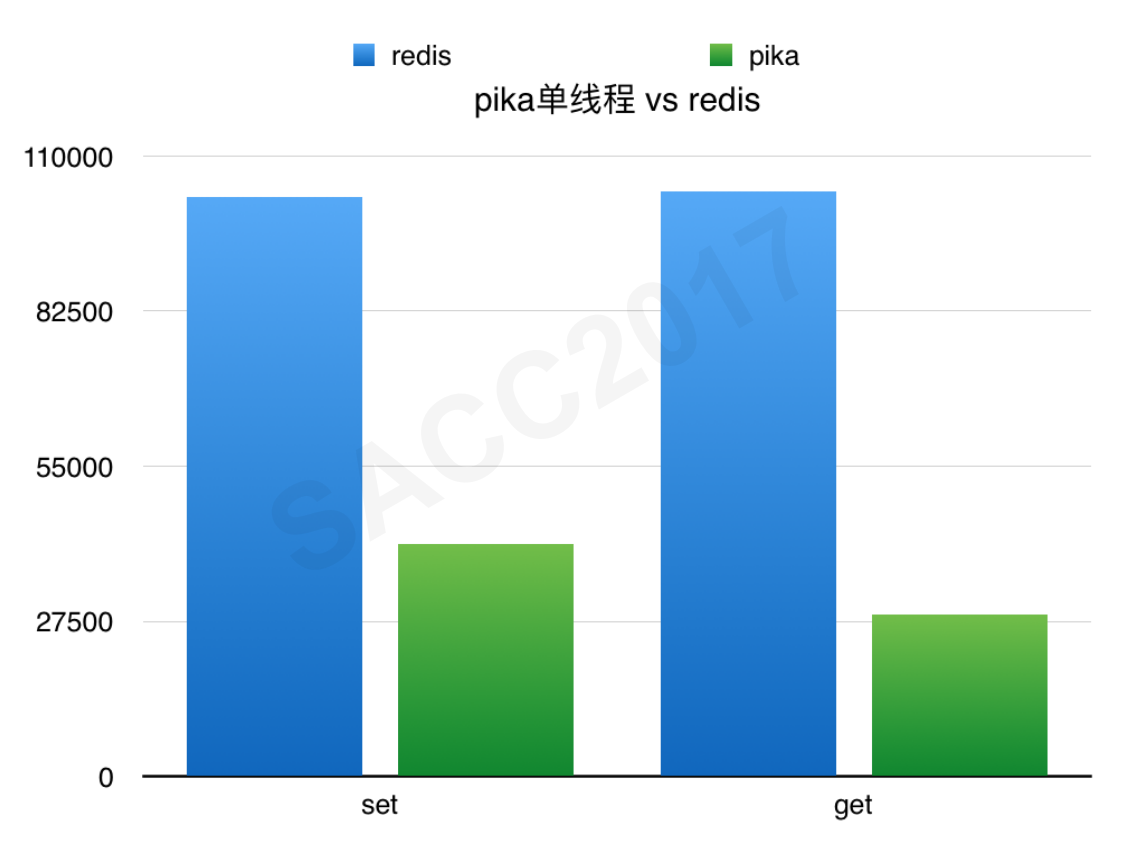

# Pika vs redis

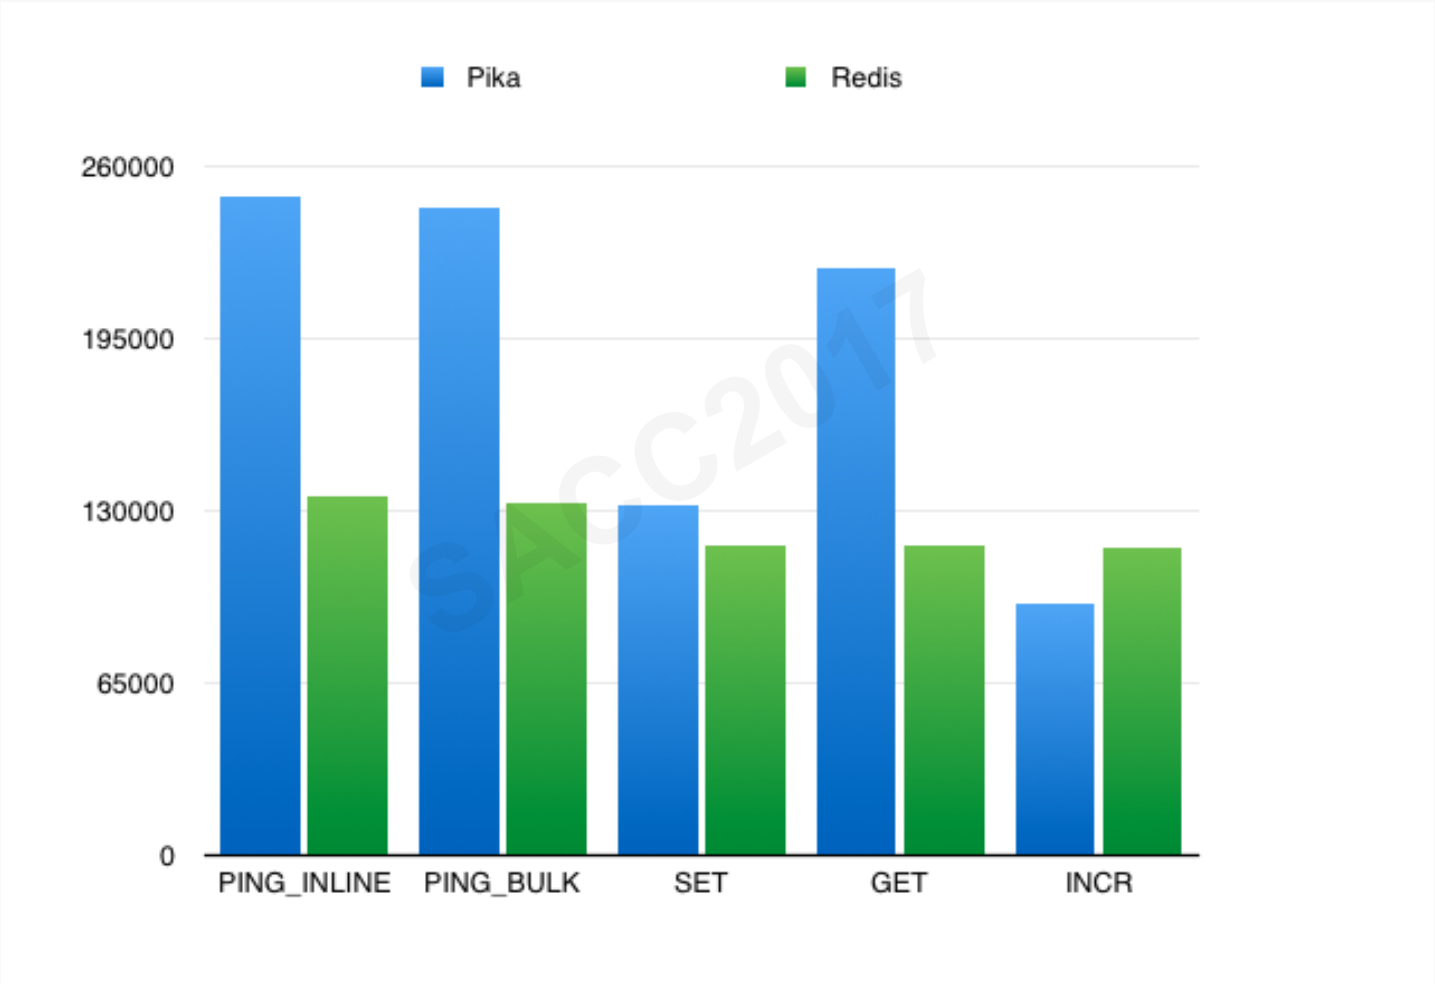

# Pika vs redis 来自vip 的测试

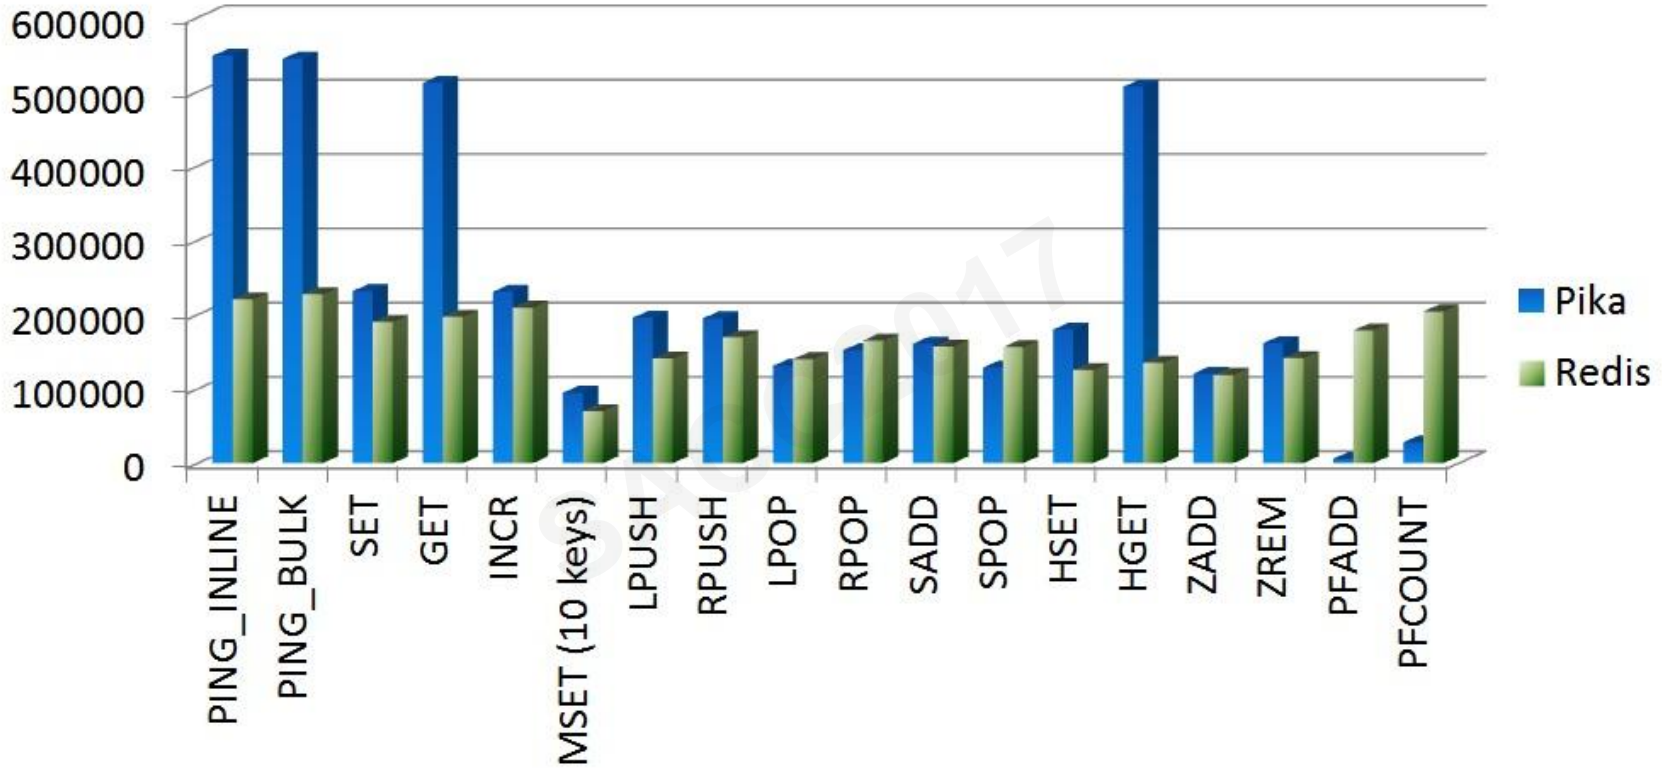


https://github.com/Qihoo360/pika

pika 技术交流

扫一扫二维码，加入该群。


THANKS